

Projet Stat'App

Catégorisation non supervisée et semi-supervisée de produits dans la Google Product Taxonomy

Salah Eddine Nejjari Tao Dang Tran Thomas Favre Yohan Andriamampionona

ENSAE Paris – Projet Stat'App

Mai 2026

- ➊ **Axe 1 – Vue générale du projet**
- ➋ **Axe 2 – Données, prétraitement et enrichissement des catégories**
- ➌ **Axe 3 – Catégorisation supervisée du Niveau 1**
- ➍ **Axe 4 – Zéro-shot L2–L7 et conclusion**

Axe 1 – Vue générale du projet

Partie 3

Comprendre les données

- Volumétrie du catalogue
- Langue dominante
- Déséquilibre des catégories
- Structure de la taxonomie
- Préparation train/test

Partie 4

Mieux représenter les catégories

- Noms de catégories parfois courts
- Prototypes textuels enrichis
- Similarité produit-catégorie
- Couverture du sens sémantique
- Préparation du L1 et L2-L7

Ces deux étapes justifient les choix de modélisation : **modèle anglais, supervisé L1, zéro-shot L2-L7, prototypes enrichis.**

Statistique	Valeur
Produits	128 253
Catégories L1 annotées	21
Nœuds taxonomie	5 440
Profondeur maximale	7
Marques distinctes	3 970
Marques manquantes	16 374
Prix manquants	993
Prix médian	75.99
Titre / description médiane	9 / 46 mots

Lecture rapide

- Base suffisamment large pour exploiter des régularités.
- Taxonomie très profonde : problème hiérarchique.
- Vérité terrain fiable uniquement au Niveau 1.
- Les niveaux L2–L7 nécessitent une stratégie zéro-shot.

Message clé : le projet est contraint par la profondeur de la taxonomie et l'absence de labels profonds.


Code	Langue	Part
en	English	99.89%
es	Spanish	0.03%
fr	French	0.02%
it	Italian	0.02%
autres	Autres	0.05%

Interprétation

- Corpus presque entièrement anglophone.
- Modèle multilingue peu nécessaire.
- Modèle anglais compact plus cohérent avec la contrainte de coût.

Choix méthodologique : privilégier des embeddings anglais, légers et efficaces.

Distribution des produits annotés au Niveau 1



À retenir

- Fort déséquilibre entre classes.
- Plusieurs grandes catégories à 20 000 produits.
- Catégories rares très peu représentées.

Une bonne micro-accuracy peut cacher de faibles performances sur les classes rares.

Structure du fichier final

Colonne	Type	Rôle
hashed_external_id	Identifiant haché	Suivi et jointures
text	Texte consolidé	Entrée principale des embeddings
sale_price	Numérique	Signal auxiliaire conservé
level_1_name	Label catégoriel	Supervision L1
brand_encoded	Marque encodée	Extension future possible

Le texte devient la variable centrale ; prix et marque sont conservés comme signaux auxiliaires.

Transition – Pourquoi enrichir les catégories ?

Problème

- Certains labels sont courts.
- Certains labels sont ambigus.
- Un nom unique couvre mal le vocabulaire produit.

Solution

- Plusieurs prototypes par catégorie.
- Nom canonique + enfants + variantes lexicales.
- Comparaison par similarité cosinus.

On passe d'une catégorie représentée par **un seul point** à une catégorie représentée par **une région sémantique**.

Formalisation des prototypes enrichis

Représentation d'une catégorie

$$P_c = \{p_c^{name}, p_c^{children}, p_{c,1}^{lex}, \dots, p_{c,r}^{lex}\}$$

Score produit-catégorie

$$S(x, c) = \max_{p \in P_c} \cos(f(x), f(p))$$



- x : produit
- c : catégorie
- P_c : prototypes de la catégorie
- $f(x)$: embedding produit
- $f(p)$: embedding prototype
- $\max$: prototype le plus proche

Le maximum évite de diluer le signal : un seul prototype pertinent peut suffire.

Recouvrement du manifold sémantique



Recouvrement du manifold sémantique par les prototypes de categorie

Sans enrichissement : un prototype unique



Un seul prototype échantillonne mal la région sémantique de la catégorie.

Avec enrichissement : couverture du manifold



Les prototypes enrichis recouvrent mieux le manifold : le max choisit le point le plus proche.


Illustration en dimension $d=3$; dans le système réel, les embeddings sont de dimension beaucoup plus élevée.

Interprétation : avec un seul prototype, la catégorie est mal couverte ; avec plusieurs prototypes, le produit peut trouver un voisin sémantique plus proche.

Catégories proches et prototypes multiples

Manifolds sémantiques entrelacés : pourquoi multiplier les prototypes aide

Deux catégories proches avec peu de points



Prototypes enrichis : meilleure séparation locale




Illustration qualitative : les vrais manifolds sont inconnus, mais les prototypes enrichis les échantillonnent plus finement.

Interprétation : lorsque deux catégories sont proches ou entrelacées, multiplier les prototypes augmente les chances de trouver le bon voisin sémantique local.

Ce que montre la Partie 3

- Base large : 128 253 produits.
- Corpus anglophone : 99.89%.
- Labels fiables seulement en L1.
- Taxonomie profonde : 5 440 nœuds, 7 niveaux.
- Forte hétérogénéité des classes L1.

Ce que construit la Partie 4

- Représentation enrichie des catégories.
- Prototypes multiples par catégorie.
- Score par similarité cosinus maximale.
- Meilleure couverture du sens taxonomique.
- Base commune pour L1 et L2–L7.

Conclusion : L'analyse descriptive et l'enrichissement des catégories ont permis de transformer un catalogue brut en un espace textuel et sémantique exploitable pour la modélisation.

Axe 4 – Du Niveau 1 supervisé aux niveaux profonds

Point de départ

- Le **Niveau 1** est appris par fine-tuning supervisé.
- Il sert de porte d'entrée dans le bon sous-arbre taxonomique.
- Il réduit fortement l'espace de recherche.

Changement de problème

- Les niveaux **L2 à L7** n'ont pas de ground truth fiable.
- On ne peut donc pas entraîner ni évaluer avec une accuracy classique.
- On passe à une logique de **recherche zéro-shot** dans la taxonomie.

L'idée est donc : **prédire L1 proprement**, puis **affiner le chemin taxonomique sans supervision** à l'aide des embeddings et des catégories enrichies.

Méthodologie d'évaluation non supervisée

Famille	Métriques	Ce que l'on mesure
Coût d'inférence	Temps total, ms / produit, débit, mémoire, millions d'opérations / produit	Viabilité opérationnelle du pipeline : latence, passage à l'échelle, coût vectoriel, charge mémoire.
Confiance interne	Marge top-1/top-2, profondeur moyenne, nombre de chemins, part du chemin majoritaire, entropie	Stabilité de la décision : un pipeline peut être profond mais peu fiable si plusieurs chemins restent presque ex-aequo.
Comparaison entre pipelines	Accord exact, accord niveau par niveau L2-L7, profondeur du premier désaccord, V de Cramér	Cohérence relative entre méthodes sans vérité terrain. Un V élevé avec un accord exact faible signifie une structure commune mais des chemins différents.
Audit NLP externe	Score bi-encodeur, score cross-encodeur, win rate, rang moyen	Préférence sémantique externe entre plusieurs chemins concurrents proposés pour un même produit.

Sans accuracy L2-L7, on compare les pipelines par **coût**, **stabilité** et **cohérence relative**.

Pourquoi Qwen3 pour L2–L7 ?

Modèle	Dim.	Temps	Débit	Taille
Qwen3	1024	163.2 min	17.0 txt/s	650.6 MB
Jasper	2048	121.6 min	22.8 txt/s	1301.1 MB

- Jasper encode plus vite, mais ses embeddings doublent le coût vectoriel et la mémoire.
- Qwen3 est plus favorable pour toutes les comparaisons produit-catégorie et produit-chemin.
- Le choix final est donc **Qwen3** pour la phase L2–L7.

Pipeline 1 – Décodage hiérarchique local

Principe

Après la prédiction du Niveau 1, on descend dans le sous-arbre correspondant. À chaque niveau, on compare le produit aux enfants du nœud courant.

$$s(x, c) = \max_{p \in \mathcal{P}_c} \cos(g(x), g(p))$$

Variantes

- **Greedy** : un seul chemin conservé.
- **Beam search** : plusieurs chemins candidats.
- **Beam + reranker** : reclassement final des meilleurs chemins.

Bilan

- Avantage : très naturel pour une taxonomie.
- Limite greedy : propagation d'erreur.
- Le beam corrige partiellement ce défaut, mais coûte plus cher.

Pipeline 2 – Clustering hiérarchique

Principe

Dans une branche L1 donnée, on suppose que les produits des catégories enfants forment des groupes dans l'espace d'embeddings.

$$\min_{\mu_1, \dots, \mu_K} \sum_{i=1}^n \min_{k \in \{1, \dots, K\}} \|z_i - \mu_k\|_2^2$$

Étapes

- Lire dans la taxonomie le nombre d'enfants.
- Former ce nombre de clusters.
- Associer chaque centroïde à une catégorie enrichie.

Bilan

- Avantage : révèle une structure collective.
- Limite : une catégorie n'est pas toujours un cluster géométrique.

Pipeline 3 – Recherche de chemins globaux

Principe

On encode les chemins complets L2–L7 une seule fois, puis on compare directement le produit à tous les chemins compatibles avec le Niveau 1 prédit.

$$\hat{h} = \arg \max_{h \in \mathcal{H}(\hat{c}_1)} \cos(g(x), g(h))$$

Intuition

- On évite les décisions locales irréversibles.
- Le chemin complet est évalué comme une hypothèse unique.

Bilan


- Avantage : plus diversifié, souvent plus profond.
- Limite : marges top-1/top-2 faibles entre chemins très proches.
- Très utile comme **méthode de désaccord**.

Résultats – Coût et performance des pipelines

Pipeline Qwen3	ms/prod.	M ops/prod.	Prof. moy.
Greedy	1.14	0.39	3.08
Beam	2.71	0.62	3.22
Beam + reranker	16.17	0.62 + rerank	3.21
Clustering	0.71	0.42	3.01
Recherche globale	1.67	0.51	3.37

Greedy est le meilleur compromis coût / latence ; **recherche globale** est la plus diversifiée ; **beam** + **reranker** apporte de la qualité brute mais change d'ordre de grandeur en coût.

Résultats – Accord entre pipelines et V de Cramér



Métrique	Qwen3	Jasper
Même chemin	1.3%	1.9%
V moyen	0.426	0.446
Même L2	15.0%	13.6%
Même L3	13.1%	19.8%
Dernier niv. commun	2.49	2.46

Bilan

- Faible accord exact.
- Mais association catégorielle non nulle.
- Les pipelines partagent souvent L2 puis divergent vite.

Scorer	Pipeline	Win Qwen	Rang Qwen
Bi-encodeur	Greedy	29.5%	2.50
Bi-encodeur	Recherche globale	20.1%	2.94
Cross-encodeur	Greedy	17.0%	2.92
Cross-encodeur	Beam + reranker	37.5%	2.15

Bilan

- Le **greedy** reste très compétitif en win rate.
- Le **beam + reranker** est le meilleur en qualité brute au cross-encodeur.
- Le reranker doit donc rester **sélectif**, pas systématique.

Ce que l'on retient

- Qwen3 est l'encodeur retenu pour L2–L7.
- Le **greedy** est la baseline la plus crédible.
- Le **beam + global path + reranker** reste utile pour les cas ambigus.

Conclusion méthodologique

- Traiter tout le catalogue avec une méthode légère.
- Utiliser les désaccords entre pipelines comme signal d'incertitude.
- Réserver le reranking à une seconde passe ciblée.

Conclusion : pour les niveaux 2 à 7, nous retenons un pipeline zéro-shot avec **Qwen3**, un **greedy** comme stratégie de base et un **reranking sélectif** uniquement pour les produits réellement ambigus.

Conclusion globale – Ce que le projet apporte

Pipeline finale

- Catégories enrichies par prototypes textuels.
- **Level 1** supervisé avec **BGE-small** fine-tuné.
- **Levels 2–7** en zéro-shot avec **Qwen3**.

Idée centrale

- Garder une approche **compacte** et **peu coûteuse**.
- Utiliser la hiérarchie taxonomique comme contrainte.
- Réserver les méthodes coûteuses aux cas difficiles.

Le projet propose une **méthodologie complète** : enrichissement, fine-tuning, pipelines zéro-shot, métriques non supervisées et benchmark de coût d'inférence.

Améliorations modèles

- Adapter davantage les embeddings au vocabulaire métier.
- Ajouter des signaux structurés comme le prix.
- Apprendre un reranker spécialisé sur la taxonomie Critéo.

Améliorations pipeline

- Construire un jeu annoté **L2–L7** pour une vraie évaluation supervisée.
- Utiliser des pseudo-labels à forte marge et de l'annotation active.
- Optimiser l'inférence à grande échelle : batchs, parallélisation, pré-calcul distribué.

La suite naturelle du projet est de transformer une pipeline zéro-shot crédible en une pipeline **semi-supervisée**, progressivement validée par des labels profonds et optimisée pour le passage à l'échelle.

Travail en équipe et apport du projet

Travail en équipe

- Répartition des tâches entre data, modélisation, expérimentation et restitution.
- Aller-retour constants entre code, analyse et rapport.
- Construction progressive d'une pipeline cohérente malgré des contraintes fortes.

Ce que le projet nous a apporté

- Travailler sur un vrai problème industriel sous contrainte de coût.
- Concevoir une évaluation même sans ground truth complète.
- Relier recherche appliquée, engineering et communication des résultats.

Ce projet nous a surtout appris à construire une solution **pragmatique et défendable**, en combinant rigueur méthodologique, expérimentation et travail collectif.